

1 随机事件和概率

随机事件及其运算

基本定义

随机试验具有**可重复性**、**可能结果多样性**、**不可预测性**。

随机试验 E 所有可能的结果组成的集合称为**样本空间**，记作 Ω ；样本空间的元素，也就是随机试验 E 的直接结果，称为**样本点**，记作 ω 。

在随机试验中可能发生也可能不发生的事件称为**随机事件**，用大写英文字母 A, B, C 记录。随机事件的本质是样本点的集合，也就是 Ω 的子集，因此有：

$$A \subseteq \Omega \implies A \text{ 为随机事件}$$

同时，

$$\text{随机事件 } A \text{ 发生} \iff \omega \in A$$

随机事件是单点集，则称作**基本事件**；是全集 Ω ，称为**必然事件**；是空集 \emptyset ，称为**不可能事件**。

随机事件的运算及运算律

1. $A \subseteq B \iff (\forall \omega)(\omega \in A \rightarrow \omega \in B)$ ，即 A 发生 B 一定发生。
2. $A = B \iff A \subseteq B \wedge B \subseteq A$ ，即 A, B 同时发生。
3. 和事件 $A \cup B$ ，也记作 $A + B$ ，即 $A \cup B$ 发生，则 A, B 至少其一发生。

多个事件的和事件 $\bigcup_{i=1}^n A_i$ ， n 可以为 $+\infty$ 。

4. 积事件 $A \cap B$ ，也记作 AB ，即 $A \cap B$ 发生，则 A, B 必共同发生。

多个事件的积事件 $\bigcap_{i=1}^n A_i$ ， n 可以为 $+\infty$ 。

5. **互不相容**（互斥事件）若 $AB = \emptyset$ ，则称 A, B 互不相容（或为互斥事件）。

若 A_1, A_2, \dots, A_n 两两互斥，即为 $A_i A_j = \emptyset (i, j = 1, 2, \dots, n)$ ， n 可以为 $+\infty$ 。

6. **逆事件**（对立事件）若 $A \cap B = \emptyset, A \cup B = \Omega$ ，则称 B 是 A 的对立事件（逆事件），记作 $\bar{A} = B$ 。

7. **差事件** $A - B$ ，即 A 发生且 B 不发生，即 $A\bar{B}$ 。

运算律（和集合论类似）

1. 吸收律： $A \cup \Omega = \Omega, A \cap \Omega = A, A \cup \emptyset = A, A \cap \emptyset = \emptyset, A \cup (AB) = A, A \cap (A + B) = A$ ；
2. 重余律： $\bar{\bar{A}} = A$ ；
3. 幂等律： $A \cup A \cup \dots \cup A = A, A \cap A \cap \dots \cap A = A$ ；
4. $A - B = A\bar{B} = A - AB$ ；
5. 交换律： $A \cap B = B \cap A, A \cup B = B \cup A$ ；
6. 结合律： $A \cup (B \cup C) = (A \cup B) \cup C, A \cap (B \cap C) = (A \cap B) \cap C$ ；
7. 分配律： $(A \cup B) \cap C = (A \cap C) \cup (B \cap C), (A \cap B) \cup C = (A \cup C) \cap (B \cup C)$ ；
8. 对偶律： $\overline{A \cup B} = \bar{A} \cap \bar{B} = \bar{A}\bar{B}, \overline{A \cap B} = \bar{A} \cup \bar{B} = \bar{A} \cup \bar{B}$ ；

对偶律可以推广： $\overline{\bigcup_{i=1}^n A_i} = \bigcap_{i=1}^n \bar{A}_i, \overline{\bigcap_{i=1}^n A_i} = \bigcup_{i=1}^n \bar{A}_i$ 。

概率

事件 A 发生的可能性大小数值估量称为 A 的概率，记作 $P(A)$ 。

古典概型

特点： Ω 仅有有限个样本点，每个基本事件发生的可能性大小相同。若满足这两条性质，则为古典概型。

记 $n = \#\Omega, k = \#A$ 分别表示总基本事件个数以及组成 A 的基本事件个数，那么有**古典概型概率公式**：

$$P(A) = \frac{k}{n} = \frac{\#A}{\#\Omega}$$

几何概型

设 Ω 为一个有界区域上的所有点， A 为 Ω 上任意子区域，在 Ω 中完全随机任意取点，则取点落入 A 的概率为

$$P(A) = \frac{m(A)}{m(\Omega)}$$

其中， $m(\cdot)$ 为测度；在一维平面上， $m(A) = l_A$ 为 A 长度；二维平面上， $m(A) = S_A$ 为区域 A 面积。

此时我们称上面这种概型为**几何概型**。

【注意】 $\forall a \in \Omega, P(\{a\}) = 0$ ，说明**概率为0的事件不一定为不可能事件；但不可能事件概率为0**。

统计概率

设 $A \subseteq \Omega$ ，在相同条件下重复试验 n 次，其中 A 发生了 n_A 次，则称

$$f_n(A) = \frac{n_A}{n}$$

为 A 在这 n 次试验中发生的**频率**。频率有如下性质：

- $f_n(A) \in [0, 1]$;
- $f_n(\Omega) = 1, f_n(\emptyset) = 0$;
- 可加性：若 A_1, A_2, \dots, A_n 两两互斥，则 $f_n(\cup_{i=1}^n A_i) = \sum_{i=1}^n f_n(A_i)$;
- **频率具有稳定性**。

概率的统计定义 在相同条件下重复进行的 n 次试验中，事件 A 发生的频率稳定在一常数 p 附近，在其附近摆动，且随着 n 增大而摆动越小，称 p 为 A 发生概率，记作 $P(A) = p$ 。

概率的公理化定义

设 \mathcal{F} 为所有事件的全体，即为**事件域**（集合的集合）。

定义集函数 $P(\cdot) : \mathcal{F} \rightarrow \mathbb{R}$ ，将每一个事件 A 映射到一个概率 $P(A)$ 上。

概率的公理化定义 (Ω, \mathcal{F}) 上的概率实质上是 \mathcal{F} 上满足下列三条的集函数：

- **非负性**： $\forall A \in \mathcal{F}, P(A) \geq 0$;
- **归一性**： $P(\Omega) = 1$;
- **可列可加性**：若 $A_1, A_2, \dots, A_n, \dots$ 为可列的两两互斥事件，则

$$P(\cup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$$

则称 (Ω, \mathcal{F}, P) 为**概率空间**。显然, (Ω, \mathcal{F}) 上的概率不唯一。

概率的基本性质

- $P(\emptyset) = 0$;

证明: 利用可列可加性: 由于 $\emptyset \cup \emptyset \cup \dots \cup \emptyset = \emptyset$, 从而 $P(\emptyset) = \sum_{i=1}^{\infty} P(\emptyset)$, 因此 $P(\emptyset) = 0$ 。

- **有限可加性**: 设 A_1, A_2, \dots, A_n 为两两互斥事件, 则

$$P(\cup_{i=1}^n A_i) = \sum_{i=1}^n P(A_i)$$

证明: 利用可列可加性, 令 $A_{n+1} = A_{n+2} = \dots = \emptyset$, 则

$P(\cup_{i=1}^n A_i) = \sum_{i=1}^n P(A_i) + \sum_{i=n+1}^{\infty} 0$ 。得证。

- $0 \leq P(A) \leq 1, P(A) = 1 - P(\bar{A})$;

证明: 利用有限可加性和归一性, $1 = P(\Omega) = P(A) + P(\bar{A})$ 。

- $\forall A, B \in \mathcal{F}, P(B - A) = P(B) - P(AB) = P(A \cup B) - P(A)$;

证明: 由于 $B = (B - A) + AB, A \cup B = (B - A) + A$, 利用有限可加性即可。

- 特别地, 若 $A \subseteq B$, 则 $P(B - A) = P(B) - P(A)$;

- $\forall A, B \in \mathcal{F}$,

$P(A \cup B) = P(A) + P(B - A) = P(A) + P(B) - P(AB) \leq P(A) + P(B)$; 称为**次可加性或概率的加法公式**。

- $\forall A, B, C \in \mathcal{F}$,

$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(AB) - P(AC) - P(BC) + P(ABC)$, 称为**容斥原理或多除少补原理**。

条件概率

基本定义

一般地, $\forall A, B \in \mathcal{F}, P(A) > 0$, 则称 $P(B|A)$ 为事件 A 发生的条件下, 事件 B 发生的**条件概率**, 定义为

$$P(B|A) = \frac{P(AB)}{P(A)}$$

则 $P(\cdot|A)$ 为 (Ω, \mathcal{F}) 上集函数, 容易验证满足概率公理化定义三条性质, 因此 $P(\cdot|A)$ 是 (Ω, \mathcal{F}) 上的一种概率, 具有上节中叙述的概率的全部性质。

乘法公式

由条件概率定义可得乘法公式:

$$P(AB) = P(A)P(B|A) = P(B)P(A|B)$$

以及推广的乘法公式:

$$P(A_1 A_2 \dots A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1 A_2) \dots P(A_n|A_1 A_2 \dots A_{n-1})$$

全概率公式

一般把 A 设为所关心事件, B_1, B_2, \dots, B_n 为 n 种可能情况, 若满足:

- $\Omega = \cup_{i=1}^n B_i$;
- $B_i B_j = \emptyset (i, j = 1, 2, \dots, n, i \neq j)$

则

$$P(A) = \sum_{i=1}^n P(B_i)P(A|B_i)$$

Bayes 公式

一般把 A 设为所关心事件, B_1, B_2, \dots, B_n 为 n 种可能情况, 若满足:

- $\Omega = \cup_{i=1}^n B_i$;
- $B_i B_j = \emptyset \ (i, j = 1, 2, \dots, n, i \neq j)$

则

$$P(B_i|A) = \frac{P(AB_i)}{P(A)} = \frac{P(B_i)P(A|B_i)}{\sum_{j=1}^n P(B_j)P(A|B_j)}$$

事件的独立性

若 $P(B|A) = P(B)$, 则称 A 对 B **没有影响**; 如果 A 对 B 没有影响且 B 对 A 没有影响, 则 A, B **互不影响**。

设 $A, B \in \mathcal{F}$, 若 $P(AB) = P(A)P(B)$, 则称事件 A, B **相互独立**。

独立的性质

- Ω 和 \emptyset 和任何事件都独立;
 - 若 A, B 独立, 则 $A, \bar{B}, \bar{A}, B, \bar{A}, \bar{B}$ 独立。
 - 如 $0 < P(A) < 1$, 则 A, B 独立 $\iff P(B|A) = P(B|\bar{A}) = P(B)$ 。
 - 若 $P(A)P(B) > 0$ 则 A, B 互不相容 $\implies A, B$ 不相互独立
- 证明: 若 A, B 互不相容, 则 $P(AB) = 0 < P(A)P(B)$, 从而不相互独立。

独立性的判定

- 利用定义, $P(AB) = P(A)P(B)$ 。
- 利用性质3, 若 $P(B|A) = P(B)$ 或 $P(B|\bar{A}) = P(B)$, 则 A, B 相互独立。
- 由题意判断 A, B 是否存在影响。

n 个事件的独立性 若 n 个事件 A_1, A_2, \dots, A_n 满足如下式子

$$\begin{aligned} P(A_i A_j) &= P(A_i)P(A_j) (1 \leq i < j \leq n) \\ P(A_i A_j A_k) &= P(A_i)P(A_j)P(A_k) (1 \leq i < j < k \leq n) \\ &\vdots \\ P(A_1 A_2 \dots A_n) &= P(A_1)P(A_2) \dots P(A_n) \end{aligned}$$

则称 A_1, A_2, \dots, A_n **相互独立**。

n 个事件独立性的判定 两种方法, ① 由定义; ② 由题意判定。

n 个事件独立性的性质 若 A_1, A_2, \dots, A_n 相互独立, 则将 n 个事件分成 k 组, 对每组事件进行求和、积、差、逆等运算后得到的 k 个事件也相互独立。

2 随机变量及其分布

随机变量

设 E 是随机试验, Ω 为 E 样本空间, \mathcal{F} 为事件域, 若有单实值函数 $X(\cdot) : \Omega \rightarrow \mathbb{R}$, 即 $\forall x, \{\omega : X(\omega) \leq x\} \in \mathcal{F}$, 则称 $X(\omega)$ 为**随机变量**。

分类：离散、非离散（其中一类为连续型）

设 X 为随机变量，则 $\forall x \in \mathbb{R}$ ，**分布函数** 定义为 $F(x) \stackrel{\text{def}}{=} P(\{X \leq x\})$ 。

分布函数的性质

- $0 \leq F(x) \leq 1, F(+\infty) = 1, F(-\infty) = 0$;
- **单调不减**: $\forall x_1 < x_2, F(x_1) \leq F(x_2)$;
- **右连续性**: $F(x+0) = F(x)$ 。

分布函数的判定 任意函数满足上述三条即可作为分布函数。

分布函数的其他性质 若 X 分布函数 $F(x)$ ，则

- $P(a \leq X \leq b) = F(b) - F(a-0)$;
- $P(a < X < b) = F(b-0) - F(a)$;
- $P(X = a) = F(a) - F(a-0)$ 。

离散型随机变量

基本定义

若随机变量 X 所有可能取值为有限个或可列无穷多个，则称 X 为**离散型随机变量**；用**分布列/分布律**描述分布：

$$P(X = x_i) = p_i \quad (i = 1, 2, 3, \dots, n, \dots)$$

X	x_1	x_2	...	x_n
P	p_1	p_2	...	p_n

一般令 $x_1, x_2, \dots, x_n, \dots$ 递增。

离散型随机变量的分布函数：

$$F(x) = P(X \leq x) = \sum_{x_k \leq x} P(X = x_k)$$
$$P(X = x_k) = p_k = P(x_{k-1} < X \leq x_k) = F(x_k) - F(x_{k-1})$$

常见分布

两点分布（0-1分布） 若随机变量 X 满足

$$P(X = k) = p^k(1-p)^{1-k}, (k = 0, 1)$$

则称 X 服从参数为 p 的0-1分布。

二项分布（伯努利分布） 独立重复做 n 次试验，每次有 p 概率成功， $1-p$ 概率失败，最后成功次数 X 服从的分布即为二项分布。即若 X 分布列满足：

$$P(X = k) = C_n^k p^k (1-p)^{n-k} (k = 0, 1, \dots, n)$$

此时称 X 服从二项分布，记作 $X \sim B(n, p)$ 。可以发现两点分布即为 $n = 1$ 的二项分布 $B(1, p)$ 。

二项分布的最可能取值 若 $X \sim B(n, p)$ ，则若 $(n+1)p$ 为整数，概率在 $k = (n+1)p - 1$ 与 $k = (n+1)p$ 取最大值，否则 $((n+1)p$ 非整数) 概率在 $k = [(n+1)p]$ 取最大值，其中 $[\cdot]$ 意为取整。

Poisson分布（泊松分布） 若随机变量 X 分布列为 $P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!} (k = 0, 1, 2, \dots)$ ，则称 X 服从参数为 λ 的泊松分布，记作 $X \sim \pi(\lambda)$ 或 $X \sim P(\lambda)$ 。

Poisson定理 设 $\lim_{n \rightarrow \infty} np_n = \lambda > 0$, 则对于固定 k , 有

$$\lim_{n \rightarrow \infty} C_n^k p_n^k (1 - p_n)^{n-k} = e^{-\lambda} \frac{\lambda^k}{k!} \quad (k = 0, 1, 2, \dots)$$

当 $n > 100, p < 0.05$ 时可以认为 $C_n^k p_n^k (1 - p_n)^{n-k} \approx e^{-\lambda} \frac{\lambda^k}{k!}$ 。

连续型随机变量

基本定义

设 X 是一随机变量, $X \sim F(x)$, 若 $\exists f(x)$, 使得 $\forall x \in \mathbb{R}, F(x) = P(X \leq x) = \int_{-\infty}^x f(u)du$, 则称 X 为**连续型随机变量**, 称 $f(x)$ 为概率密度函数。显然连续型随机变量的分布函数 $F(x)$ 绝对连续且唯一, 概率密度函数 $f(x)$ 不唯一。

概率密度函数的性质

- $f(x) > 0$;
- $\int_{-\infty}^{+\infty} f(x)dx = F(+\infty) = 1$;
- $f(x)$ 连续点时有 $F'(x) = f(x)$;
- $f(x_0)\Delta x \approx P(x_0 < X \leq x_0 + \Delta x)$;
- $P(a < X \leq b) = P(a < X < b) = P(a \leq X < b) = P(a \leq X \leq b) = F(b) - F(a)$;
- $\forall k, P(X = k) = 0$ 。

概率密度函数的判定 满足性质1, 2的函数即可作为概率密度函数。

常见分布

区间 (a, b) 上的均匀分布 若 X 的密度函数 $f(x)$ 满足:

$$f(x) = \begin{cases} \frac{1}{b-a} & (x \in (a, b)) \\ 0 & (x \notin (a, b)) \end{cases}$$

则称 X 满足区间 (a, b) 上的均匀分布, 记作 $X \sim U(a, b)$ 。其分布函数 $F(x)$ 为:

$$F(x) = \begin{cases} \frac{x-a}{b-a} & (x \in (a, b)) \\ 0 & (x \leq a) \\ 1 & (x \geq b) \end{cases}$$

指数分布 若 X 的密度函数 $f(x)$ 为

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & (x \geq 0) \\ 0 & (x < 0) \end{cases}$$

则称 X 满足参数为 λ 的指数分布, 记作 $X \sim E(\lambda)$ 。其分布函数 $F(x)$ 为

$$F(x) = \begin{cases} 1 - e^{-\lambda x} & (x \geq 0) \\ 0 & (x < 0) \end{cases}$$

指数分布的性质

- $P(a < X < b) = e^{-\lambda a} - e^{-\lambda b}$;
- **无记忆性**: 若 $X \sim E(\lambda)$, 则 $P(t < X \leq t + \Delta t | X > t) = P(0 < X \leq \Delta t) \quad (\Delta t > 0)$ 。

正态分布 若随机变量 X 的密度函数 $f(x)$ 为

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

则称 X 服从参数为 μ, σ^2 的正态分布, 记为 $X \sim N(\mu, \sigma^2)$ 。其分布函数 $F(x)$ 为超越函数。

标准正态分布 随机变量 $X \sim N(0, 1)$, 则其分布函数 $\varphi(x)$ 为

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

分布函数 $\Phi(x)$ 满足 $\Phi(x) + \Phi(-x) = 1$, 因此 (标准) 正态分布具有对称性。标准正态分布函数可以查表。

正态分布转化为标准正态分布 若 $X \sim N(\mu, \sigma^2)$, 则 $\frac{X-\mu}{\sigma} \sim N(0, 1)$ 。

随机变量函数的分布

离散型随机变量函数的分布

一般方法 设 X 是离散型随机变量, $Y = g(X)$, 则求 Y 的分布的一般方法如下:

- $Y = y_1, y_2, \dots, y_k$ (求出 Y 所有可能取值);
- $P(Y = y_i) = P(g(X) = y_i) = \sum_{g(x_j)=y_i} p_j$ 。

连续型随机变量函数的分布

一般方法 设 X 是连续性随机变量, $Y = g(X)$, 则求 Y 分布的一般方法如下:

- 先求分布函数 $F_Y(y) = P(Y \leq y) = P(g(X) \leq y) = \int_{g(x) \leq y} f_X(x) dx$;
- 对于 y 求导即得概率密度函数 $f_Y(y) = \frac{d}{dy} F_Y(y)$ 。

定理 设 X 具有概率密度函数 $f_X(x)$, $g(x)$ 为 \mathbb{R} 上严格单调可导函数, 则 $Y = g(X)$ 密度函数为

$$\begin{aligned} f_Y(y) &= |h'(y)| f_X(h(y)) \quad (y \in (\alpha, \beta)) \\ f_Y(y) &= 0 \quad (y \notin (\alpha, \beta)) \end{aligned}$$

3 多维随机变量及其分布

二维随机变量及其分布

设 E 是随机试验, Ω 为 E 样本空间, \mathcal{F} 为事件域, 若函数 $X \times Y: \Omega \rightarrow \mathbb{R}^2$, 则称 (X, Y) 为**二维随机变量**。

联合分布函数 设 (X, Y) 为二维随机变量, $\forall (x, y)$, $F(x, y) \stackrel{\text{def}}{=} P(X \leq x, Y \leq y)$ 为二维随机变量 (X, Y) 的联合分布函数。

联合分布函数的性质

- $0 \leq F(x, y) \leq 1, F(+\infty, +\infty) = 1, F(\cdot, -\infty) = F(-\infty, \cdot) = 0$;
- $F(x, y)$ 对于 x, y 均单调不减; 即固定 x (或 y), $F(x, y)$ 关于 y (或 x) 单调不减;
- 对 x, y 均右连续, 即 $F(x_0, y) = F(x_0, y+0), F(x, y_0) = F(x+0, y_0)$;
- 对任意 $a < b, c < d$, 有

$$F(b, d) - F(b, c) - F(a, d) + F(a, c) = P(a < X \leq b, c < Y \leq d) \geq 0$$

联合分布函数的判定 满足上述四条性质的 $F(x, y)$ 可以称为联合分布函数。

边缘分布函数 设 (X, Y) 联合分布函数为 $F(x, y)$, 则 X, Y 各自的分布函数称为边缘分布函数, 为

$$F_X(x) = F(x, +\infty), F_Y(y) = F(+\infty, y)$$

联合分布函数唯一确定边缘分布函数, 反之不真。

二维离散型随机变量

若二维随机变量的所有可能取值为有限多个或无穷可列多个, 则称 (X, Y) 为**二维离散型随机变量**。
 (X, Y) 的联合分布律 (联合分布列) 为:

$$P(X = x_i, Y = y_j) = p_{i,j} \quad (i, j = 1, 2, \dots)$$

Y/P/X	x_1	x_2	...	x_n
y_1	$p_{1,1}$	$p_{2,1}$...	$p_{n,1}$
y_2	$p_{1,2}$	$p_{2,2}$...	$p_{n,2}$
...
y_m	$p_{1,m}$	$p_{2,m}$...	$p_{n,m}$

性质 $p_{i,j} > 0$, $\sum_i \sum_j p_{i,j} = 1$ 。

判定 若满足如上性质可作为二维离散型随机变量的联合分布列。

边缘分布列 $P(Y = y_j) = \sum_i p_{i,j}$, $P(X = x_i) = \sum_j p_{i,j}$ 。

二维连续型随机变量

基本定义 设 (X, Y) 联合分布函数 $F(x, y)$, 若 $\exists f(x, y) \geq 0$, 使得
 $\forall x, y, F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(x, y) dx dy$, 则称 (X, Y) 为二维连续型随机变量, $f(x, y)$ 称为其联合密度函数。

联合密度函数的性质

- $f(x, y) \geq 0$;
- $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(u, v) du dv = F(+\infty, +\infty) = 1$;
- 设 G 为平面上区域, 则 $P((x, y) \in G) = \iint_G f(u, v) dS$;
- 若 $f(x, y)$ 在 (x_0, y_0) 处二元连续, 则
 $f(x_0, y_0) = \frac{\partial^2}{\partial x \partial y} F(x, y)|_{x=x_0, y=y_0} = \frac{\partial^2}{\partial y \partial x} F(x, y)|_{x=x_0, y=y_0}$ 。

联合密度函数的判定 满足性质1, 2的函数即可作为联合密度函数。

边缘密度函数 $f_X(x) = F'_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy$, $f_Y(y) = F'_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx$ 。

常见分布

均匀分布 设 D 为平面上一个有界区域, 若 $f(x, y)$ 满足

$$f(x, y) = \frac{1}{S_D} ((x, y) \in D)$$
$$f(x, y) = 0 ((x, y) \notin D)$$

则称 (X, Y) 服从区域 D 上均匀分布, 记作 $(X, Y) \sim U(D)$ 。

二维正态分布 若 (X, Y) 具有概率密度

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}[(\frac{x-\mu_1}{\sigma_1})^2 - 2\rho(\frac{x-\mu_1}{\sigma_1})(\frac{y-\mu_2}{\sigma_2}) + (\frac{y-\mu_2}{\sigma_2})^2]}$$

其中, $\sigma_1 > 0, \sigma_2 > 0, \rho \in (-1, 1)$ 。

则称 (X, Y) 服从参数为 $\mu_1, \sigma_1^2; \mu_2, \sigma_2^2; \rho$ 的二维正态分布, 记作 $(X, Y) \sim N(\mu_1, \sigma_1^2; \mu_2, \sigma_2^2; \rho)$ 。

则边缘密度函数 $f_X(x) = \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}}$, $f_Y(y) = \frac{1}{\sqrt{2\pi}\sigma_2} e^{-\frac{(y-\mu_2)^2}{2\sigma_2^2}}$ 。

注 若 X, Y 均服从正态分布, 那么 (X, Y) 不一定服从二维正态分布!

反例 $f(x, y) = \frac{1}{2\pi} e^{-\frac{x^2+y^2}{2}} (1 + \sin x \sin y)$, 容易发现 $X, Y \sim N(0, 1)$ 。

二维随机变量的条件分布

问题 已知 (X, Y) 联合分布, 求 $X = x_0$ 下 Y 的分布。

二维离散型随机变量

一般方法 设 $P(X = x_i, Y = y_j) = p_{i,j}$, 且 $p_{i,\cdot} = P(X = x_i) = \sum_j p_{i,j} > 0$, 则

$$P(Y = y_j | X = x_i) = \frac{P(X = x_i, Y = y_j)}{P(X = x_i)} = \frac{p_{i,j}}{p_{i,\cdot}} = \frac{p_{i,j}}{\sum_{j'} p_{i,j'}}$$

二维连续型随机变量

一般方法 设 $(X, Y) \sim f(x, y)$, $X \sim f_X(x)$, $Y \sim f_Y(y)$, 则 $X = x$ 下 Y 分布为:

$$F_Y(y | X = x) = \frac{\int_{-\infty}^y f(x, t) dt}{f_X(x)}$$
$$f_Y(y | X = x) = \frac{f(x, y)}{f_X(x)}$$

注: $F_{X|Y}(x|y), f_{X|Y}(x|y)$ 是 x 的函数, y 为常数!

性质

- $f_X(x | Y = y_0) = k f(x, y_0)$, 则 $k = \frac{1}{f_Y(y_0)}$;
- 连续情况下的条件概率乘法公式 $f(x, y) = f_X(x) f_{Y|X}(y|x) = f_Y(y) f_{X|Y}(x|y)$;
- 连续情况下的全概率公式 $f_X(x) = \int_{-\infty}^{+\infty} f_Y(y) f_{X|Y}(x|y) dy$;
- 二维正态分布的条件分布仍然是正态分布!

随机变量的独立性

离散型随机变量

对二维离散型随机变量, 若满足对于任意 (x_i, y_j) 都有 $P(X = x_i, Y = y_j) = P(X = x_i)P(Y = y_j)$, 即 $p_{i,j} = p_{i,\cdot} p_{\cdot,j}$, 则称 X, Y **互相独立**。

若 X, Y 互相独立, 则 $P(X = x_i | Y = y_j) = P(X = x_i)$, 即已知 Y 取值不影响 X 的分布。

连续型随机变量

设 (X, Y) 联合密度函数 $f(x, y)$, 边缘密度函数 $f_X(x), f_Y(y)$, 若 $f(x, y) = f_X(x) f_Y(y)$ 在 $f(x, y)$ 的连续点都成立, 则称 X, Y **互相独立**。

独立性质及判定: X, Y 独立 $\iff f_X(x|Y = y) = f_X(x) \iff f_Y(y|X = x) = f_Y(y)$ 。

独立必要条件: 区域为直矩形区域 (根据定义可得)。

判定定理 设 $f(x, y)$ 为 (X, Y) 联合密度函数, 则 X, Y 相互独立的充要条件为存在非负可积 $r(x), g(y)$, 使得 $f(x, y) = r(x)g(y)$ 在 $f(x, y)$ 一切连续点成立。

二维正态分布独立的判定 $\rho = 0$ 。

一般随机变量

一般地, 若对任意 x, y 均有 $P(X \leq x, Y \leq y) = P(X \leq x)P(Y \leq y)$, 即 $F(x, y) = F_X(x)F_Y(y)$, 则称 X, Y **互相独立**。实际上, 该定义等价于任意选取一个矩形区域满足相乘条件 (即等价于 $\forall a < b, c < d$, 有 $P(a \leq X \leq b, c \leq Y \leq d) = P(a \leq X \leq b)P(c \leq Y \leq d)$)。

等价描述 实际上, 还等价于 $\forall B_x, B_y, P(X \in B_x, Y \in B_y) = P(X \in B_x)P(Y \in B_y)$ 。

性质 如果 X, Y 独立, 则随机变量的函数 $g(X), h(Y)$ 独立。

随机变量相互独立性推广为 n 维 如果 n 维随机变量 (X_1, X_2, \dots, X_n) 满足

- $P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n) = \prod_{i=1}^n P(X_i \leq x_i)$
- 或 $F(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F_{X_i}(x_i)$

则称 X_1, X_2, \dots, X_n 相互独立。

多维随机变量函数的分布

离散型随机变量

具有可加性的两个分布的叠加

- 若 $X_1 \sim B(n, p), X_2 \sim B(m, p)$, 则 $X_1 + X_2 \sim B(n + m, p)$;
- 若 $X_1 \sim P(\lambda_1), X_2 \sim P(\lambda_2)$, 则 $X_1 + X_2 \sim P(\lambda_1 + \lambda_2)$ 。

一般方法 当 (X, Y) 为离散型随机变量时, $Z = g(X, Y)$ 也是离散型随机变量, 其中

$$P(Z = z_k) = P(g(X, Y) = z_k) = \sum_{g(x_i, y_j) = z_k} P(X = x_i, Y = y_j) = \sum_{g(x_i, y_j) = z_k} p_{i,j}$$

连续型随机变量

一般方法 当 $(X, Y) \sim f(x, y), Z = g(X, Y)$, 则

$$F_Z(z) = P(Z \leq z) = P(g(X, Y) \leq z) = \iint_{g(X, Y) \leq z} f(x, y) dx dy$$

进而, $f_Z(z) = F'_Z(z)$ 即得概率密度函数。

$Z = X + Y$ 的密度函数

$$F_Z(z) = P(X + Y \leq z) = \int_{x+y \leq z} f(x, y) dx dy = \int_{-\infty}^{+\infty} dx \int_{-\infty}^{z-x} f(x, y) dy$$
$$f_Z(z) = F'_Z(z) = \int_{-\infty}^{+\infty} f(x, z-x) dx = \int_{-\infty}^{+\infty} f(z-y, y) dy$$

当 X, Y 独立时, $f_Z(z) = \int_{-\infty}^{+\infty} f_X(x) f_Y(z-x) = (f_X * f_Y)(z)$ 为**卷积**。

正态分布的可加性 若 X, Y 独立, 且 $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$, 那么 $X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$ 。

$Z = X/Y$ 的密度函数

$$F_Z(z) = P(X/Y \leq z) = \int_{x/y \leq z} f(x, y) dx dy = \int_0^{+\infty} \int_{-\infty}^{yz} f(x, y) dx dy + \int_{-\infty}^0 \int_{yz}^{+\infty} f(x, y) dx dy$$
$$f_Z(z) = F'_Z(z) = \int_0^{+\infty} y f(yz, y) dy - \int_{-\infty}^0 y f(yz, y) dy = \int_{-\infty}^{+\infty} |y| f(yz, y) dy$$

$Z = X^2 + Y^2$ 密度函数

$$F_Z(z) = P(X^2 + Y^2 \leq z) = \iint_{x^2+y^2 \leq z} f(x, y) dx dy = \int_0^{\sqrt{z}} r dr \int_0^{2\pi} f(r \cos \theta, r \sin \theta) d\theta \quad (z \geq 0)$$

$$f_Z(z) = F'_Z(z) = \frac{1}{2} \int_0^{2\pi} f(\sqrt{z} \cos \theta, \sqrt{z} \sin \theta) d\theta \quad (z \geq 0)$$

特别地, n 个独立的标准正态分布的平方和为自由度为 n 的**卡方分布**。

$M = \max(X, Y), m = \min(X, Y)$ **极值分布**

$$F_M(z) = P(\max(X, Y) \leq z) = P(X \leq z, Y \leq z) = F(z, z)$$

$$F_m(z) = P(\min(X, Y) \leq z) = 1 - P(X > z, Y > z)$$

注 可以推广至 n 个变量的极值分布。

4 随机变量的数字特征

数学期望

离散型随机变量的数学期望 设 X 为离散型随机变量, 其分布律为 $P(X = x_k) = p_k \quad (k = 1, 2, \dots)$, 若无穷级数 $\sum_{k=1}^{+\infty} p_k x_k$ 绝对收敛, 则称其和为随机变量 X 的数学期望, 记为 $EX = \sum_{k=1}^{+\infty} p_k x_k$ 。

二项分布的数学期望

$$X \sim B(n, p)$$

$$EX = \sum_{k=0}^n k C_n^k p^k (1-p)^{n-k} = \sum_{k=1}^n n \frac{(n-1)!}{(n-k)!(k-1)!} p \cdot p^{k-1} (1-p)^{n-k} = np \sum_{k=1}^n C_{n-1}^{k-1} p^{k-1} (1-p)^{n-k}$$

$$EX = np \sum_{k=0}^{n-1} C_{n-1}^k p^k (1-p)^{n-1-k} = np$$

泊松分布的数学期望

$$X \sim P(\lambda)$$

$$EX = \sum_{i=0}^{\infty} i \cdot \frac{\lambda^i}{i!} e^{-\lambda} = e^{-\lambda} \lambda \sum_{i=1}^{\infty} \frac{\lambda^{i-1}}{(i-1)!} = \lambda e^{-\lambda} \sum_{i=0}^{+\infty} \frac{\lambda^i}{i!} = e^{-\lambda} \lambda e^{\lambda} = \lambda$$

连续型随机变量的数学期望 设连续型随机变量的概率密度为 $f(x)$, 若积分 $\int_{-\infty}^{+\infty} x f(x) dx$ 绝对收敛, 则称此积分的值为 X 的数学期望, 记作 $EX = \int_{-\infty}^{+\infty} x f(x) dx$ 。

正态分布的数学期望 若 $X \sim N(\mu, \sigma^2)$, 则 $EX = \mu$ 。

均匀分布的数学期望 若 $X \sim U(a, b)$, 则 $EX = \frac{a+b}{2}$ 。

指数分布的数学期望 (利用分部积分)

$$X \sim E(\lambda)$$

$$EX = \int_0^{+\infty} x f(x) dx = \int_0^{+\infty} x \cdot \lambda e^{-\lambda x} dx = \dots = \frac{1}{\lambda}$$

随机变量函数的期望 设 Y 为 X 的分段连续函数, 若 $Y = g(X)$, $E(Y)$ 存在, 则

- 对离散型随机变量 X , 若 $P(X = x_k) = p_k$, 则 $EY = E(g(X)) = \sum_k g(x_k) p_k$;
- 对连续型随机变量 X , 若概率密度为 $f(x)$, 则 $EY = E(g(X)) = \int_{-\infty}^{+\infty} g(x) f(x) dx$ 。

设 Z 为 X, Y 的函数, $Z = g(X, Y)$ 且 g 连续, 则

- 对离散型随机变量, $EZ = \sum_i \sum_j g(x_i, y_j) p_{i,j}$;
- 对连续型随机变量, $EZ = \iint_{\mathbb{R}^2} g(x, y) f(x, y) dx dy$ 。

几个重要的随机变量函数期望的定义

- k 阶原点矩: $E(X^k)$;
- k 阶绝对原点矩: $E(|X|^k)$;
- k 阶中心矩: $E((X - EX)^k)$;
- 方差 (2 阶中心矩): $E((X - EX)^2)$;
- 偏度 (3 阶中心矩): $E((X - EX)^3)$;
- 峰度 (4 阶中心矩): $E((X - EX)^4)$ 。

数学期望的性质 设 X, Y 为随机变量, a, b, c 为常数

- X 期望存在 $\iff E(|X|) < +\infty$;
- $X \leq Y$, 则 $E(X) \leq E(Y)$;
- $a \leq X \leq b$, 则 $a \leq E(X) \leq b$;
- **线性性**: $E(aX + bY + c) = aE(X) + bE(Y) + c$;
线性性推广: $E(\sum_{i=1}^n a_i X_i) = \sum_{i=1}^n a_i E(X_i)$;
- 若 X, Y 独立, 则 $E(XY) = E(X)E(Y)$, **逆命题不真**;
推广: 若 X_1, X_2, \dots, X_n 相互独立, 则 $E(\prod_{i=1}^n X_i) = \prod_{i=1}^n E(X_i)$ 。

方差

设 X 为随机变量, 若 EX^2 绝对可积, 则称 $E(X - EX)^2$ 为 X 的**方差**, 记为 DX , 反映了 X 偏离均值程度。

标准差 (均方差) 定义为: $\sigma_X = \sqrt{DX}$ 。

计算方法

$$DX = E(X - EX)^2 = E(X^2 - 2EX \cdot X + (EX)^2) = E(X^2) - (EX)^2$$

- 由于 $DX \geq 0$, 有 $E(X^2) \geq (EX)^2$ 。
- 可以通过 EX, DX 计算 EX^2 : $EX^2 = (EX)^2 + DX$ 。

二项分布的方差

$$X \sim B(n, p)$$

$$EX^2 = \sum_{k=0}^n k^2 C_n^k p^k (1-p)^{n-k} = \sum_{k=2}^n k(k-1) \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k} + \sum_{k=1}^n k \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k}$$

$$EX^2 = n(n-1)p^2 + np$$

$$DX = EX^2 - (EX)^2 = n(n-1)p^2 + np - n^2p^2 = np - np^2 = np(1-p)$$

泊松分布的方差

$$X \sim P(\lambda)$$

$$DX = EX^2 - (EX)^2 = \sum_{k=0}^{\infty} k^2 \frac{\lambda^k}{k!} e^{-\lambda} - \lambda^2 = e^{-\lambda} \left(\lambda^2 \sum_{k=2}^{\infty} \frac{\lambda^{k-2}}{(k-2)!} + \lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} \right) - \lambda^2$$

$$DX = \lambda^2 + \lambda - \lambda^2 = \lambda$$

正态分布的方差 若 $X \sim N(\mu, \sigma^2)$, 则 $DX = \sigma^2$ 。

均匀分布的方差 若 $X \sim U(a, b)$, 则 $DX = \frac{(b-a)^2}{12}$ 。

指数分布的方差 (利用分部积分)

$$X \sim E(\lambda)$$

$$DX^2 = \int_0^{+\infty} x^2 \lambda e^{-\lambda x} dx - \left(\frac{1}{\lambda}\right)^2 = \dots = \frac{1}{\lambda^2}$$

方差的性质 设 X, Y 为随机变量, a, b, c 为常数。

- $D(c) = 0$;
- $D(cX) = c^2 D(X)$;
- 若 X, Y 独立, 则 $D(X \pm Y) = D(X) + D(Y)$;
- 一般地, $D(X \pm Y) = DX + DY \pm 2E((X - EX)(Y - EY))$ (协方差) ;
- 若 X_1, X_2, \dots, X_n 相互独立, 则 $D(\sum_{i=1}^n a_i X_i) = \sum_{i=1}^n a_i^2 D(X_i)$;
- $D(X) = E(X - EX)^2 \leq E(X - a)^2$
证明: $g(c) = E(X - c)^2 = E(X^2) - 2cEX + c^2$, 当 $c = EX$ 时 $g(c)$ 最小。
- $DX = 0 \iff \exists c, P(X = c) = 1$ (几乎处处是常数) 。

标准化随机变量 随机变量 X 的标准化随即变量 X^* 定义为:

$$X^* = \frac{X - EX}{\sqrt{DX}} \quad (DX > 0)$$

那么, $E(X^*) = 0, D(X^*) = 1$ 。

协方差和相关系数

协方差 若 X, Y 为随机变量, 定义 **协方差** 为 $\text{cov}(X, Y) = E(X - EX)(Y - EY)$ 。特别地, $DX = \text{cov}(X, X)$ 。称半正定矩阵 $A \in \mathbb{R}^{2 \times 2}$ 为 X, Y 的**协方差矩阵**, 其中 $a_{1,1} = D(X)$, $a_{2,2} = D(Y)$, $a_{1,2} = a_{2,1} = \text{cov}(X, Y) = \text{cov}(Y, X)$ 。

一般地, n 维随机变量 (X_1, X_2, \dots, X_n) 存在实对称半正定协方差矩阵 $\Sigma_n = (\text{cov}(X_i, X_j))_{n \times n}$ 。

相关系数 若 X, Y 为随机变量且 $DX > 0, DY > 0$, 则相关系数 $\rho_{X,Y}$ 定义为:

$$\rho_{X,Y} = \frac{\text{cov}(X, Y)}{\sqrt{DX}\sqrt{DY}}$$

- 相关系数 $\rho_{X,Y}$ 为无量纲量;
- $|\rho_{X,Y}|$ 的大小反映了 X, Y 背后的线性关系的强弱。

协方差的计算

- 利用定义, 计算 $E(X - EX)(Y - EY)$;
- 用公式计算: $E(X - EX)(Y - EY) = E(XY) - EX \cdot EY$ 。

协方差的性质

- **对称性:** $\text{cov}(X, Y) = \text{cov}(Y, X)$;
- $\text{cov}(aX, bY) = ab\text{cov}(X, Y)$;
- $\text{cov}(X + Y, Z) = \text{cov}(X, Z) + \text{cov}(Y, Z)$;
- $\text{cov}(X, X) = DX$;
- $\text{cov}(aX + bY, cX + dY) = acDX + (bc + ad)\text{cov}(X, Y) + bdDY$;
- $D(aX + bY) = \text{cov}(aX + bY, aX + bY) = a^2 DX + b^2 DY + 2ab\text{cov}(X, Y)$ 。

Cauchy-Schwartz不等式

$$\text{cov}^2(X, Y) \leq DXDY$$

证明: $f(t) = D(X + tY) = (DX)^2 + 2t\text{cov}(X, Y) + t^2(DY)^2 \geq 0$, 故

$$\Delta = 4\text{cov}^2(X, Y) - 4DXDY \leq 0$$

当 $t = t^* = -\frac{\text{cov}(X, Y)}{DY}$ 时, $D(X + tY)$ 最小值 $D(X + t^*Y) = DX(1 - \rho_{X, Y}^2)$ 。

二维正态分布的相关系数 若 $(X, Y) \sim N(\mu_1, \sigma_1; \mu_2, \sigma_2; \rho)$, 则 $\rho_{X, Y} = \rho$ 。

相关系数的性质

- $|\rho_{X, Y}| \leq 1$ (由 Cauchy-Schwartz 不等式直接导出) ;
- $\rho_{X, Y} = 0$ 称 X, Y **不相关**; $\rho_{X, Y} > 0$ 称 X, Y **正相关**; $\rho_{X, Y} < 0$ 称 X, Y **负相关**; $\rho_{X, Y} = 1$ 称 X, Y **完全正相关**; $\rho_{X, Y} = -1$ 称 X, Y **完全负相关**。
- $|\rho_{X, Y}| = 1 \iff D(X + t^*Y) = DX(1 - \rho_{X, Y}^2) = 0 \iff \exists c, P(X + t^*Y = c) = 1$, 几乎在一条直线上, 称**完全线性相关**。
- X, Y 不相关
 $\iff \rho_{X, Y} = 0 \iff \text{cov}(X, Y) = 0 \iff E(XY) = EXEY \iff D(X \pm Y) = DX + DY$
- **【注】** 独立一定不相关, 不相关不一定独立! !
 - 对于二维正态分布 $N(\mu_1, \sigma_1^2; \mu_2, \sigma_2^2; \rho)$, X, Y 独立 $\iff X, Y$ 不相关 $\iff \rho = 0$

Chebyshev 不等式

一般地, 有

$$P(|X - EX| \geq \varepsilon) \leq \frac{DX}{\varepsilon^2} \quad (\varepsilon > 0)$$
$$P(|X - EX| \leq \varepsilon) \geq 1 - \frac{DX}{\varepsilon^2} \quad (\varepsilon > 0)$$

证明:

$$P = P(|X - EX| \geq \varepsilon)$$
$$DX = \left(\int_{-\infty}^{EX-\varepsilon} + \int_{EX-\varepsilon}^{EX+\varepsilon} + \int_{EX+\varepsilon}^{+\infty} \right) (X - EX)^2 f(x) dx \geq \left(\int_{-\infty}^{EX-\varepsilon} + \int_{EX+\varepsilon}^{+\infty} \right) \varepsilon^2 f(x) dx = \varepsilon^2 P$$

5 大数定律与中心极限定理

大数定律

Bernoulli大数定理 设 n_A 为 n 次独立重复试验中事件 A 发生次数, p 是每次试验中 A 发生的概率, 则 $\forall \varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{n_A}{n} - p\right| \geq \varepsilon\right) = 0$$

或

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{n_A}{n} - p\right| < \varepsilon\right) = 1$$

依概率收敛 设 Y_1, Y_2, \dots, Y_n 为一随机变量序列, a 是一常数, 且 $\forall \varepsilon > 0$ 有

$$\lim_{n \rightarrow \infty} P(|Y_n - a| \geq \varepsilon) = 0$$

或

$$\lim_{n \rightarrow \infty} P(|Y_n - a| < \varepsilon) = 1$$

则称随机变量序列 Y_1, Y_2, \dots, Y_n 依概率收敛至 a , 记作 $Y_n \xrightarrow{p; n \rightarrow \infty} a$ 。

服从大数定律 若随机变量序列 X_1, X_2, \dots, X_n 具有如下性质则称这个随机变量序列服从大数定律:

$$\lim_{n \rightarrow \infty} P \left(\left| \frac{1}{n} \sum_{k=1}^n X_k - \frac{1}{n} \sum_{k=1}^n E(X_k) \right| < \varepsilon \right) = 1$$

即 $\frac{1}{n} \sum_{k=1}^n X_k$ 依概率收敛到 $\frac{1}{n} \sum_{k=1}^n E(X_k)$ 。

若 X_1, X_2, \dots, X_n 独立同分布, 则上式等价于

$$\lim_{n \rightarrow \infty} P \left(\left| \frac{1}{n} \sum_{k=1}^n X_k - EX \right| < \varepsilon \right) = 1$$

即 $\frac{1}{n} \sum_{k=1}^n X_k$ 依概率收敛到 EX 。

Chebyshev 大数定律

设随机变量序列 X_1, X_2, \dots, X_n 两两不相关, 它们的方差存在, 而且有共同上界, 即

$$E(X_k) = \mu_k, \quad D(X_k) = \sigma_k^2 \leq \sigma^2 < +\infty \quad (k = 1, 2, \dots, n)$$

则这个随机变量序列服从大数定律, 即

$$\lim_{n \rightarrow \infty} P \left(\left| \frac{1}{n} \sum_{k=1}^n X_k - \frac{1}{n} \sum_{k=1}^n \mu_k \right| < \varepsilon \right) = 1$$

证明: 令 $Y_n = \frac{1}{n} \sum_{k=1}^n X_k$, 则 $E(Y_n) = \frac{1}{n} \sum_{k=1}^n \mu_k$ 。

$$D(Y_n) = \frac{1}{n^2} D \left(\sum_{i=1}^n X_i \right) = \frac{1}{n^2} \sum_{i=1}^n D(X_i) \leq \frac{\sigma^2}{n^2} \cdot n = \frac{\sigma^2}{n}$$

根据 Chebyshev 不等式, $P(|Y_n - E(Y_n)| < \varepsilon) \geq 1 - \frac{DY_n}{\varepsilon^2} = 1 - \frac{\sigma^2}{n\varepsilon^2} \rightarrow 1 \ (n \rightarrow \infty)$ 。

即满足大数定律。

注意: 所有条件可以削弱至 **Markov 条件**

$$\frac{1}{n^2} D \left(\sum_{k=1}^n X_k \right) \xrightarrow{n \rightarrow \infty} 0$$

Khintchine 大数定律 设 X_1, X_2, \dots, X_n 独立同分布, 若它们期望存在, $E(X_i) = \mu$, 则该序列服从大数定律, 即 $\frac{1}{n} \sum_{k=1}^n X_k$ 依概率收敛到 μ , 即

$$\lim_{n \rightarrow \infty} P \left(\left| \frac{1}{n} \sum_{k=1}^n X_k - \mu \right| < \varepsilon \right) = 1$$

中心极限定理

Lindeberg-L é vy 中心极限定理 设 X_1, X_2, \dots, X_n 独立同分布, 且

$$E(X_i) = \mu, \quad D(X_i) = \sigma^2 < +\infty$$

则 $\forall x$,

$$\lim_{n \rightarrow \infty} P \left(\frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} \leq x \right) = \Phi(x)$$

即 $\sum_{i=1}^n X_i$ 近似服从 $N(n\mu, n\sigma^2)$, $Y_n = \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma}$ 在 n 很大时近似服从于 $N(0, 1)$ 。

6 数理统计的基本概念

总体与样本

总体 研究对象的全体（研究对象某项数量指标的全体）组成的集合。

个体 组成总体的每一个个体。

总体分布 总体中每个个体数量指标不同，背后有一定的分布，称为总体分布。（把总体看成一个随机变量 X ，总体分布即是随机变量 X 的分布）。

样本 从总体中随机抽取部分个体组成的集合称为样本 (X_1, X_2, \dots, X_n) , n 称为**样本容量**。

样本值（样本观察值） (x_1, x_2, \dots, x_n) 称为总体 X 的一个容量为 n 的样本观察值，即样本的一组可能取值。

样本空间 样本 (X_1, X_2, \dots, X_n) 的所有可能取值的集合，记作 \mathcal{X} 。

简单随机样本（如不加特别说明，样本默认为简单随机样本）设 (X_1, X_2, \dots, X_n) 为来自 X 的一个样本，若其满足

- X_1, X_2, \dots, X_n 与 X 同分布；
- X_1, X_2, \dots, X_n 相互独立；

则称这个样本是简单随机样本。

- 简单随机样本 (X_1, X_2, \dots, X_n) 的联合分布函数 $F(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F_X(x_i)$;
- 简单随机样本 (X_1, X_2, \dots, X_n) 的联合密度函数 $f(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f_X(x_i)$;

统计量 若 $g(x_1, x_2, \dots, x_n)$ 是不含未知参数的实值连续函数，则随机变量 $g(X_1, X_2, \dots, X_n)$ 为统计量， (x_1, x_2, \dots, x_n) 为样本 (X_1, X_2, \dots, X_n) 观察值，则 $g(x_1, x_2, \dots, x_n)$ 为统计量 $g(X_1, X_2, \dots, X_n)$ 观察值。

常用的一些统计量

- 样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, 依概率收敛至 EX ;
- 样本方差 $s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, 依概率收敛至 DX ;
- 样本均方差 $s = \sqrt{s^2}$, 依概率收敛至 \sqrt{DX} ;
- 样本 k 阶矩 $M_k = \frac{1}{n} \sum_{i=1}^n X_i^k$, 依概率收敛至 $E(X^k)$;
- 样本 k 阶中心矩 $CM_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$, 依概率收敛至 $E((X - EX)^k)$ 。
- 顺序统计量：将 (X_1, X_2, \dots, X_n) 从小到大排序后得到 $(X_{(1)}, X_{(2)}, \dots, X_{(n)})$, 即为**顺序统计量**, $X_{(1)} = \min_{i=1}^n X_i, X_{(n)} = \max_{i=1}^n X_i$, **极差** $D = X_{(n)} - X_{(1)}$ 。

抽样分布

正态分布

$$X \sim N(\mu, \sigma^2), \quad (X_1, X_2, \dots, X_n), \quad X_i \sim N(\mu, \sigma^2)$$

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

$$\sum_{i=1}^n a_i X_i \sim N\left(\mu \sum_{i=1}^n a_i, \sigma^2 \sum_{i=1}^n a_i^2\right)$$

卡方分布

设 (X_1, X_2, \dots, X_n) 独立同分布, 且 $X_i \sim N(0, 1)$, 则 $\chi^2 = X_1^2 + X_2^2 + \dots + X_n^2 = \sum_{i=1}^n X_i^2 \sim \chi^2(n)$, 称 χ^2 服从自由度为 n 的**卡方分布**。

图像 (均在 y 轴右半边)

- $n = 1$ 时候递减, 类似反比例函数;
- $n = 2$ 时候递减, $\chi^2(2) = E(\frac{1}{2})$;
- $n \geq 3$ 时出现峰, 且 n 越大峰越靠后。

性质

- **可加性**: 若 $\chi_1^2 \sim \chi^2(n_1), \chi_2^2 \sim \chi^2(n_2)$ 且 χ_1^2, χ_2^2 独立, 则 $\chi_1^2 + \chi_2^2 \sim \chi^2(n_1 + n_2)$ 。
- 若 $X \sim \chi^2(n)$, 则 (利用了自由度为2的卡方分布是参数为 $\frac{1}{2}$ 的指数分布)

$$EX = E(X_1^2 + X_2^2 + \dots + X_n^2) = \sum_{i=1}^n E(X_i^2) = n(EX_i + DX_i) = n(0 + 1) = n$$

$$DX = D(X_1^2 + X_2^2 + \dots + X_n^2) = nD(X_1^2) = \frac{n}{2}D(X_1^2 + X_2^2) = \frac{n}{2} \times \frac{1}{(\frac{1}{2})^2} = 2n$$

同时, 这个结果给出了对于服从标准正态分布 $N(0, 1)$ 的随机变量 X 的平方的期望为1, 方差为2。

查表: 若 $P(X > k) = \alpha$, 则记 $k = \chi_\alpha^2(n)$, 称其为 α -分位数。

t-分布

设 $X \sim N(0, 1), Y \sim \chi^2(n)$, X, Y 独立, 则

$$T = \frac{X}{\sqrt{\frac{Y}{n}}}$$

所服从的分布称为自由度为 n 的 t-分布。记为 $T \sim t(n)$ 。

图像&性质

- $f(t)$ 为偶函数, 图像关于 y 轴对称;
- $n \rightarrow +\infty, T \overset{\text{近似}}{\sim} N(0, 1)$ 。(根据**Khinchine大数定律**, Y/n 依概率收敛到 $E(Y_1^2) = 1$ 。

查表: 若 $P(T > k) = \alpha$, 则记 $k = t_\alpha(n)$, 称其为 α -分位数。

F-分布

设 $X \sim \chi^2(m), Y \sim \chi^2(n)$, 且 X, Y 独立, 则

$$F = \frac{\frac{X}{m}}{\frac{Y}{n}}$$

服从的分布称为第一自由度 m , 第二自由度 n 的 F-分布, 记为 $F \sim F(m, n)$ 。

图像 和卡方分布类似。

性质

- $F \sim F(m, n)$, 则 $\frac{1}{F} \sim F(n, m)$;
- $T \sim t(n)$, 则 $T^2 \sim F(1, n)$ 。

查表: 若 $P(F > k) = \alpha$, 则记 $k = F_\alpha(m, n)$, 称其为 α -分位数。

分位数性质

- $F_{1-\alpha}(m, n) = \frac{1}{F_{\alpha}(n, m)}$;

证明: $X \sim F(m, n)$, 令 $F_{1-\alpha}(m, n) = k$, 则 $P(X > k) = 1 - \alpha$, 从而 $P(X \leq k) = \alpha$, 从而 $P\left(\frac{1}{X} \geq \frac{1}{k}\right) = \alpha$, 而 $\frac{1}{X} \sim F(n, m)$, 从而 $F_{\alpha}(n, m) = \frac{1}{k}$, 从而 $F_{1-\alpha}(m, n) = \frac{1}{F_{\alpha}(n, m)}$ 。

- $[t_{1-\frac{\alpha}{2}}(n)]^2 = F_{\alpha}(1, n)$;

证明: $X \sim t(n)$, 设 $k = t_{1-\frac{\alpha}{2}}(n)$, 则 $P(X > k) = 1 - \frac{\alpha}{2}$ 。容易知道 $k \leq 0$ (因为 $P(X > k) \geq \frac{1}{2}$, t -分布具有对称性), 从而 $P(X \leq k) = \frac{\alpha}{2}$, $P(|X| > -k) = \alpha$, $P(X^2 > k^2) = \alpha$ 。又 $X^2 \sim F(1, n)$, 从而 $k^2 = F_{\alpha}(1, n)$, 于是 $[t_{1-\frac{\alpha}{2}}(n)]^2 = F_{\alpha}(1, n)$ 。

正态总体的抽样分布

一个正态总体的抽样分布

$$X \sim N(\mu, \sigma^2), \quad EX = \mu, \quad DX = \sigma^2, \quad (X_1, X_2, \dots, X_n)$$

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

$$\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma}\right)^2 \sim \chi^2(n)$$

$$\frac{n-1}{\sigma^2} s^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 \sim \chi^2(n-1)$$

$$\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$$

$$\frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} = \frac{\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}}{\sqrt{\frac{1}{n-1} \cdot \frac{n-1}{\sigma^2} s^2}} \sim t(n-1)$$

重要性质: \bar{X} 和 s 相互独立。

两个独立正态总体的分布情况 (X, Y 独立)

$$X \sim N(\mu_1, \sigma_1^2), \quad Y \sim N(\mu_2, \sigma_2^2), \quad (X_1, X_2, \dots, X_n), \quad (Y_1, Y_2, \dots, Y_m)$$

$$\bar{X} - \bar{Y} \sim N\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}\right)$$

若 $\sigma_1 = \sigma_2 = \sigma$, 则

$$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{1}{n} + \frac{1}{m}} \sigma} \sim N(0, 1)$$

$$s_w = \sqrt{\frac{n-1}{n+m-2} s_1^2 + \frac{m-1}{n+m-2} s_2^2}$$

$$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{1}{n} + \frac{1}{m}} s_w} = \frac{\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{1}{n} + \frac{1}{m}} \sigma}}{\sqrt{\frac{1}{n+m-2} \left(\frac{n-1}{\sigma_1^2} s_1^2 + \frac{m-1}{\sigma_2^2} s_2^2\right)}} \sim t(n+m-2)$$

另外还有

$$\frac{\frac{s_1^2}{\sigma_1^2}}{\frac{s_2^2}{\sigma_2^2}} = \frac{\frac{1}{n-1} \frac{n-1}{\sigma_1^2} s_1^2}{\frac{1}{m-1} \frac{m-1}{\sigma_2^2} s_2^2} \sim F(n-1, m-1)$$

$$\frac{s_1^2}{s_2^2} \sim F(n-1, m-1) \quad (\sigma_1^2 = \sigma_2^2)$$

7 参数估计

点估计法

设总体 $X \sim F(x; \theta_1, \theta_2, \dots, \theta_k)$, 其中 $\theta_1, \theta_2, \dots, \theta_k$ 为未知参数。用 k 个统计量估计 $\theta_1, \theta_2, \dots, \theta_k$ 的方法称为**点估计法**。

矩法

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n X_i &= \bar{X} \approx EX = \mu_1(\theta_1, \theta_2, \dots, \theta_k) \\ \frac{1}{n} \sum_{i=1}^n X_i^2 &= M_2 \approx EX^2 = \mu_2(\theta_1, \theta_2, \dots, \theta_k) \\ &\dots \\ \frac{1}{n} \sum_{i=1}^n X_i^k &= M_k \approx EX^k = \mu_k(\theta_1, \theta_2, \dots, \theta_k) \end{aligned}$$

一般地,

$$\begin{aligned} \hat{\mu} &= \frac{1}{n} \sum_{i=1}^n X_i = \bar{X} \\ \hat{\sigma}^2 &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = CM_2 \end{aligned}$$

注: 如果上述 k 个方程中有无用方程(恒等), 则继续往下列写, 直到有 7

极大似然估计

离散型下的似然函数 一般地, 设 X 为离散型总体, 其分布律为

$P(X=x) = p(x; \theta)$ ($x = \mu_1, \mu_2, \dots, \mu_m, \dots$), (X_1, X_2, \dots, X_n) 为总体样本, 似然函数如下定义:

$$P(X=x_1, X=x_2, \dots, X=x_n) = \prod_{i=1}^n P(X=x_i) = \prod_{i=1}^n p(x_i; \theta) \stackrel{def}{=} L(x_1, x_2, \dots, x_n; \theta)$$

离散型下的对数似然函数 一般地, 对数似然函数如下定义:

$$\ln L(x_1, x_2, \dots, x_n; \theta) = \sum_{i=1}^n \ln p(x_i; \theta)$$

连续型下的似然函数 类似地, 似然函数如下定义:

$$L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k) \stackrel{def}{=} \prod_{i=1}^n f(x_i; \theta_1, \theta_2, \dots, \theta_k)$$

连续型下的对数似然函数 一般地, 对数似然函数如下定义:

$$\ln L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k) = \sum_{i=1}^n \ln f(x_i; \theta_1, \theta_2, \dots, \theta_k)$$

方法 寻找 $\theta = \hat{\theta}$, 使得似然函数 (或对数似然函数) $L(\theta)$ (或 $\ln L(\theta)$) 取极大值, 即

$$L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} \left\{ \prod_{i=1}^n p(x_i; \theta) \right\}$$

则称这样得到的 $\hat{\theta} = g(x_1, x_2, \dots, x_n)$ 即为参数的估计值, $g(X_1, X_2, \dots, X_n)$ 为**极大似然估计量**。

若有多个参数, 则对于每个参数求偏导后令其等于0得到一个方程, 联立解出估计值即可。

极大似然估计的不变性原理 设 $\hat{\theta}$ 为 θ 的极大似然估计量, $u(\theta)$ 为 θ 的连续函数, 则 $u(\hat{\theta})$ 也为 $u(\theta)$ 的极大似然估计量。

泊松分布总体的极大似然估计 设 $X \sim P(\lambda)$, 样本 (X_1, X_2, \dots, X_n) , 则经过极大似然估计后, 有

$$\lambda = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

正态总体的极大似然估计 设 $X \sim N(\mu, \sigma^2)$, 样本 (X_1, X_2, \dots, X_n) , 则经过极大似然估计后, 有

$$\hat{\mu} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$
$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

估计量的评判标准

无偏性

设总体 $X \sim F(x; \theta)$, θ 为位置参数, $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 为 θ 的估计量 (是一个统计量!), 若对任意设定的 θ 都有 $E(\hat{\theta}) = \theta$, 则说 $\hat{\theta}$ 为 θ 的**无偏估计量**。

同一个参数的无偏估计量不唯一

- \bar{X} 为 EX 无偏估计, $\frac{1}{n} \sum_{i=1}^n X_i^k$ 为 EX^k 无偏估计;
- $CM_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 不是正态总体 $N(\mu, \sigma^2)$ 中 σ^2 的无偏估计, $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 是 σ^2 的无偏估计。

有效性

设 $\hat{\theta}_1, \hat{\theta}_2$ 都是 θ 的无偏估计量 (是统计量!), 若 $D(\hat{\theta}_1) < D(\hat{\theta}_2)$, 则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效。

Rao-Cramer不等式 若 $\hat{\theta}$ 为 θ 的无偏估计量, 则

$$D(\hat{\theta}) \geq \frac{1}{nE\left[\frac{\partial}{\partial\theta}\ln p(X, \theta)\right]^2} \stackrel{\text{def}}{=} D_0$$

有效估计量 能达到 Rao-Crammer 不等式下界的估计量。

一致性

设 $\hat{\theta}_n = \hat{\theta}(X_1, X_2, \dots, X_n)$ 为 θ 估计量, 若对任意 θ , 当 $n \rightarrow \infty$ 时, θ_n 依概率收敛至 θ , 即

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| \geq \varepsilon) = 0 \quad (\varepsilon > 0)$$

则称 $\hat{\theta}_n$ 为 θ 的**一致估计量**。

- M_k 为 EX^k 的一致估计量。
- 矩估计量一般是一致估计量。

- 若 $\hat{\theta}$ 是 θ 的一致估计量, u 为 θ 的连续函数, 则 $u(\hat{\theta})$ 为 $u(\theta)$ 的一致估计量。
- $s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 是总体方差的一致估计量。

区间估计

设 $X \sim F(x, \theta)$, θ 未知参数, 给定置信度为 $1 - \alpha$ ($0 < \alpha < 1$), 若 $\exists \hat{\theta}_1, \hat{\theta}_2$, 使得 $P(\hat{\theta}_1 \leq \theta \leq \hat{\theta}_2) = 1 - \alpha$, 则称区间 $[\hat{\theta}_1, \hat{\theta}_2]$ 为参数 θ 的置信度为 $1 - \alpha$ 的**置信区间**。

- 置信区间长度 $\hat{\theta}_2 - \hat{\theta}_1$ 反映了估计精度, 长度越小精度越高;
- 置信度 $1 - \alpha$ 反映了可靠度, α 越小精度越高;
- 先保证可靠性再提高精度, 通常 $1 - \alpha = 0.95$;
- 扩大样本容量可以提高精度。

一般方法

- 构造枢轴量 (仅含有待估参数 θ , 分布确定且不依赖于待估参数) $g(X_1, X_2, \dots, X_n; \theta)$;
- 给定置信度 $1 - \alpha$, 定出常数 a, b 使得 $P(a < g(X_1, X_2, \dots, X_n; \theta) < b) = 1 - \alpha$ (a, b 不唯一);
- 反解不等式 $a < g(X_1, X_2, \dots, X_n; \theta) < b$ 得到 $\hat{\theta}_1 < \theta < \hat{\theta}_2$ 。

一个正态总体的区间估计

- σ^2 已知, 求 μ 区间估计, 枢轴量

$$U = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$$

- σ^2 未知, 求 μ 区间估计, 枢轴量

$$T = \frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} \sim t(n-1)$$

- μ 已知, 求 σ^2 区间估计, 枢轴量

$$K = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 \sim \chi^2(n)$$

- μ 未知, 求 σ^2 区间估计, 枢轴量

$$K = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 \sim \chi^2(n-1)$$

单侧置信区间 对于给定 α , θ 待估, 若存在 $\underline{\theta}$ 使得 $P(\underline{\theta} \leq \theta) = 1 - \alpha$, 则称 $(\underline{\theta}, +\infty)$ 为 θ 的**单侧置信区间**, $\underline{\theta}$ 为**置信下限**; 同理有**置信上限**和另一个**单侧置信区间**。

两个正态总体的参数估计 (X, Y 独立)

$$X \sim N(\mu_1, \sigma_1^2), \quad Y \sim N(\mu_2, \sigma_2^2), \quad (X_1, X_2, \dots, X_n), \quad (Y_1, Y_2, \dots, Y_m)$$

- σ_1, σ_2 已知, 求 $(\mu_1 - \mu_2)$ 置信区间, 枢轴量

$$U = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} \sim N(0, 1)$$

- σ_1, σ_2 未知, 但有 $\sigma_1^2 = \sigma_2^2$, 求 $(\mu_1 - \mu_2)$ 置信区间, 枢轴量

$$s_w = \sqrt{\frac{n-1}{n+m-2} s_1^2 + \frac{m-1}{n+m-2} s_2^2}$$

$$T = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{s_w \sqrt{\frac{1}{n} + \frac{1}{m}}} \sim t(n+m-2)$$

- σ_1, σ_2 未知, 大样本, 可以近似估计 $\hat{\sigma}_1^2 = s_1^2, \hat{\sigma}_2^2 = s_2^2$ 后利用 $U \sim N(0, 1)$ 。
- μ_1, μ_2 不要求, 求 $\frac{\sigma_1^2}{\sigma_2^2}$ 置信区间, 枢轴量

$$F = \frac{\frac{s_1^2}{s_2^2}}{\frac{\sigma_1^2}{\sigma_2^2}} = \frac{\frac{1}{n-1} \frac{n-1}{\sigma_1^2} s_1^2}{\frac{1}{m-1} \frac{m-1}{\sigma_2^2} s_2^2} \sim F(n-1, m-1)$$

8 假设检验

对一个或多个总体的分布或参数作假设。从总体中抽样, 用统计的方法对假设合理性做出判断, 这类方法称作**假设检验** (统计假设检验)。假设检验分为参数检验和非参数检验。其理论依据: 实际推断原理 (小概率原理), 即小概率事件在一次试验中不会发生。

一般方法

- 建立假设, H_0 为原假设 (偶然因素导致的为原假设, 一般为题目所问), H_1 为备选假设 (H_0, H_1 不能交换且 H_0, H_1 互斥但并集为全集); 如果 H_0 涉及到复合假设如 $H_0: \mu \geq 70$, 应该简单化得到 $H_0: \mu = 70$ 。
- 选择适当统计量 $T = g(X_1, X_2, \dots, X_n)$ (要求 H_0 成立条件下, T 的分布完全已知); 给定显著性水平 α , 依据 $P_{H_0}(T \in W) \leq \alpha$ 构造拒绝域 W 。
- 代入数据检验: $\hat{T} = g(X_1, X_2, \dots, X_n)$, 如果 $\hat{T} \in W$, 则拒绝 H_0 ; 否则接受 H_0 。

注意

- 拒绝域由备选假设决定, α 越大越容易拒绝;
- 两类错误:
 - 第一类错误: 拒绝 H_0 但是 H_0 为真;
 - 第二类错误: 接受 H_0 但是 H_0 为假;
 - 犯第一类错误概率减小必然导致犯第二类错误概率增大, 反之亦然;
 - 应该尽可能避免犯第一类错误, 控制犯第一类错误的概率为 α ;
 - 要使犯两类错误概率都减小——扩大样本容量。

一个正态总体的参数检验

- 关于 μ 检验: $H_0: \mu = \mu_0, H_1: \mu \neq \mu_0$:
 - 方差 σ^2 已知, 则

$$U = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \stackrel{H_0}{\sim} N(0, 1)$$

称为 U-检验法;

- 方差 σ^2 未知, 则

$$T = \frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} \stackrel{H_0}{\sim} t(n-1)$$

称为 T-检验法;

- 关于 σ^2 的检验: $H_0: \sigma^2 = \sigma_0^2, H_1: \sigma^2 \neq \sigma_0^2$:
 - 均值 μ 已知, 则

$$K = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 \stackrel{H_0}{\sim} \chi^2(n)$$

- 均值 μ 未知, 则

$$K = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 \stackrel{H_0}{\sim} \chi^2(n-1)$$

上述均称为 K-检验法。

两个正态总体的参数检验 (X, Y 独立)

$$X \sim N(\mu_1, \sigma_1^2), \quad Y \sim N(\mu_2, \sigma_2^2), \quad (X_1, X_2, \dots, X_n), \quad (Y_1, Y_2, \dots, Y_m)$$

- 检验 $(\mu_1 - \mu_2)$, $H_0: \mu_1 - \mu_2 = \delta, H_1: \mu_1 - \mu_2 \neq \delta$ 。

- σ_1, σ_2 已知, 则

$$U = \frac{\bar{X} - \bar{Y} - \delta}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} \stackrel{H_0}{\sim} N(0, 1)$$

- σ_1, σ_2 未知, 但有 $\sigma_1^2 = \sigma_2^2$, 则

$$s_w = \sqrt{\frac{n-1}{n+m-2} s_1^2 + \frac{m-1}{n+m-2} s_2^2}$$

$$T = \frac{\bar{X} - \bar{Y} - \delta}{s_w \sqrt{\frac{1}{n} + \frac{1}{m}}} \stackrel{H_0}{\sim} t(n+m-2)$$

- 检验 $\frac{\sigma_1^2}{\sigma_2^2}$, $H_0: \frac{\sigma_1^2}{\sigma_2^2} = \delta, H_1: \frac{\sigma_1^2}{\sigma_2^2} \neq \delta$, 则

$$F = \frac{1}{\delta} \frac{s_1^2}{s_2^2} \sim F(n-1, m-1)$$

称为 F-检验法。